

طرح درس و برنامه تدریس هر جلسه

سیستم‌های خبره (مهندسی مدل‌های زبانی بزرگ)

مدرسین:

دکتر سعید رضا خردپیشه

میلاد وزان



فهرست مطالب

۲	معرفی درس
۲	هدف درس:
۳	در پایان درس، دانشجو باید بتواند:
۳	سرفصل‌های اصلی درس
۴	ارزشیابی درس
۴	راه‌های ارتباطی و دریافت کمک
۴	سیاست همکاری
۵	برنامه تدریس
۵	پارت ۱: تکامل و مبانی هوش مصنوعی (۲ جلسه)
۵	جلسه ۱: سیر تکامل هوش مصنوعی و مفاهیم بنیادین
۵	جلسه ۲: مرور کامل شبکه‌های عصبی (Pre-requisite)
۵	پارت ۲: زیرساخت و مبانی مدل‌های زبانی (۶ جلسه)
۵	جلسه ۳: Embedding و Tokenization
۶	جلسه ۴: معماری Transformer (بخش اول - Attention)
۶	جلسه ۵: معماری Transformer (بخش دوم - ساختار کامل)
۶	جلسه ۶: Embedding و Prediction Heads های مدرن
۷	جلسه ۷: پایگاه‌های داده برداری + ChromaDB
۷	جلسه ۸: چالش‌ها و محدودیت‌های LLM
۷	پارت ۳: استدلال
۷	جلسه ۹: مهندسی پرامپت پیشرفته
۸	پارت ۴: دانش خارجی و RAG (۵ جلسه)
۸	جلسه ۱۰: مبانی RAG (Retrieval-Augmented Generation)
۸	جلسه ۱۱: روش‌های پیشرفته بازیابی
۹	جلسه ۱۲: بهینه‌سازی مرحله بازیابی (Retrieval Optimization)
۹	جلسه ۱۳: ارزیابی سیستم‌های RAG و مدل‌های زبانی بزرگ
۱۰	جلسه ۱۴: کارگاه عملی RAG (پروژه کامل)
۱۰	پارت ۵: Fine-tuning و بهینه‌سازی (۲ جلسه)
۱۰	جلسه ۱۵: مبانی Fine-tuning و LoRA
۱۱	جلسه ۱۶: تقطیر دانش (Knowledge Distillation) و فشرده‌سازی مدل
۱۱	پارت ۶: Agentic AI (۶ جلسه)
۱۱	جلسه ۱۷: تعاریف و تمایزات کلیدی
۱۲	جلسه ۱۸: معماری Agent و Tool Calling
۱۲	جلسه ۱۹: الگوهای طراحی Agent
۱۳	جلسه ۲۰: سیستم‌های چندعامله (Multi-Agent Systems) - بخش اول
۱۳	جلسه ۲۱: پیاده‌سازی عملی Multi-Agent
۱۴	جلسه ۲۲: حافظه در سیستم‌های Agentic
۱۵	پارت ۷: مباحث تکمیلی و پیشرفته (۳ جلسه)
۱۵	جلسه ۲۳: معماری‌های پیشرفته و مدل‌های جدید
۱۶	جلسه ۲۴: ارزیابی و تست سیستم‌های Agentic
۱۷	جلسه ۲۵: ایمنی، حریم خصوصی و استقرار مسئولانه
۱۷	جلسه ۲۶: پروژه پایانی
۱۷	مراجع و منابع درس

معرفی درس

عنوان درس:

سیستم‌های خبره (مهندسی مدل‌های زبانی بزرگ - Engineering for Large Language Models)

سطح:

کارشناسی

پیش‌نیاز:

برنامه‌نویسی پایتون، مفاهیم پایه یادگیری ماشین

مدرسین:

دکتر سعیدرضا خردپیشه، میلاد وزان

معرفی درس:

این درس یک دوره جامع و پیشرفته در حوزه هوش مصنوعی مولد (Generative AI) و سیستم‌های عامل محور (Agentic AI) است که از مبانی پایه تا معماری‌های پیشرفته و پیاده‌سازی عملی را پوشش می‌دهد. دانشجویان در این دوره با مفاهیم بنیادین شبکه‌های عصبی، معماری Transformer، مدل‌های زبانی بزرگ (LLM)، سیستم‌های بازیابی-تولید (RAG)، تکنیک‌های تنظیم دقیق (Fine-tuning) و طراحی عامل‌های هوشمند (AI Agents) آشنا می‌شوند.

این سرفصل به گونه‌ای طراحی شده که دانشجو را از مفاهیم پایه‌ای تا لبه‌ترین تکنولوژی‌های روز پیش ببرد و پاسخی باشد به نیاز روزافزون صنعت به نیروی متخصص در حوزه سیستم‌های مبتنی بر مدل‌های زبانی بزرگ. این درس با نگاهی جامع و کاربردی، تلاش دارد تا شکاف میان مبانی نظری هوش مصنوعی و نیازهای عملی صنعت را پر کند.

هدف درس:

نگاه آینده‌نگرانه

- آشنایی با معماری‌های نوین مانند MoE، Mamba و مدل‌های استدلال‌گر که نسل بعدی سیستم‌های هوش مصنوعی را شکل می‌دهند.
- بررسی روندهای پژوهشی در زمینه حافظه عامل‌ها، سیستم‌های چندعامله، و مقیاس‌پذیری استنتاج.
- توانایی تحلیل و پیش‌بینی تحولات آتی در حوزه عامل‌های هوشمند خودمختار و تعامل انسان-ماشین.

ارتباط با صنعت و نیازهای بازار کار

- آموزش ابزارها و فریم‌ورک‌های پرکاربرد در صنعت: Hugging Face، ChromaDB، FastAPI و استانداردهای MCP و A2A.
 - پیاده‌سازی پروژه‌های واقعی شامل سیستم RAG کامل، عامل‌های مکالمه‌ای و سیستم‌های چندعامله با قابلیت استقرار.
 - آشنایی با بهینه‌سازی‌های عملیاتی مانند کاهش هزینه و افزایش سرعت
- ارتباط با پژوهش و رویکرد آکادمیک
- مطالعه عمیق مقالات بنیادین و جدیدترین یافته‌ها در حوزه‌های Attention، RAG، Agentic Memory و Reasoning.
 - ارائه پروژه‌های پایانی که می‌توانند به مقالات علمی یا طرح‌های منبع‌باز تبدیل شوند.

در پایان درس، دانشجو باید بتواند:

دانش و درک (Knowledge)

- معماری Transformer، مکانیزم‌های Attention، و روش‌های توکن‌سازی و Embedding را به‌خوبی توضیح دهد.
- تفاوت مدل‌های مولد، عامل‌محور، و سنتی را به‌درستی تشخیص دهد.
- چالش‌های کلیدی مانند توهم، محدودیت پنجره زمینه، و سوگیری داده را تحلیل کند.

مهارت‌های تحلیلی (Analytical Skills)

- یک سیستم RAG را از صفر طراحی، پیاده‌سازی، و با معیارهای مناسب ارزیابی کند.
- روش‌های مختلف بازیابی را مقایسه و بهترین گزینه را انتخاب کند.
- مدل‌های زبانی را با تکنیک‌های کارآمد (مانند LORA) تنظیم دقیق کند و تأثیر آن را بسنجد.

مهارت‌های عملی (Practical Skills)

- با ابزارهایی مانند Hugging Face Transformers، ChromaDB، LangChain و FastAPI کار کند.
- عامل‌های هوشمند با قابلیت فراخوانی ابزار (Tool Calling) و حافظه بلندمدت طراحی و پیاده‌سازی کند.
- سیستم‌های چندعامله با نقش‌های تخصصی (مانند پژوهشگر، نویسنده، داور) را پیاده‌سازی و هماهنگی بین آن‌ها را مدیریت کند.

رویکرد انتقادی و پژوهشی (Research Thinking & Critical)

- نقاط قوت و ضعف روش‌های مختلف فشرده‌سازی، تقطیر دانش، و ارزیابی را بررسی کند.
- سناریوهای شکست عامل‌ها را پیش‌بینی و راهکارهای بازیابی ارائه دهد.
- یافته‌های خود را در قالب یک پروژه پایانی با مستندات علمی و کد عملیاتی ارائه کند.

سرفصل‌های اصلی درس

- پارت ۱: تکامل و مبانی هوش مصنوعی (۲ جلسه)
- پارت ۲: زیرساخت و مبانی مدل‌های زبانی (۶ جلسه)
- پارت ۳: مهندسی پرامپت پیشرفته و استدلال (۱ جلسه)
- پارت ۴: دانش خارجی و RAG (۵ جلسه)
- پارت ۵: تنظیم دقیق و بهینه‌سازی (۲ جلسه)
- پارت ۶: هوش مصنوعی عامل‌محور (۶ جلسه)
- پارت ۷: مباحث تکمیلی، ارزیابی و استقرار (۳ جلسه)
- پروژه پایانی: طراحی و پیاده‌سازی یک سیستم جامع

مؤلفه ارزشیابی	نمره	توضیحات
حضور و مشارکت فعال	۲ نمره	حضور منظم در کلاس و مشارکت در مباحث علمی، پرسش و پاسخ و بحث‌های گروهی
تکالیف عملی	۶ نمره	۴ تا ۶ تمرین عملی
پروژه پایانی با گزارش	۹ نمره	پروژه جامع پایان ترم شامل طراحی، پیاده‌سازی، ارزیابی، و مستندسازی کامل
آزمون پایان ترم	۳ نمره	آزمون جامع شامل مفاهیم نظری، تحلیلی، و مسائل کاربردی
مجموع	۲۰ نمره	

راه‌های ارتباطی و دریافت کمک

برای رفع ابهامات و دریافت راهنمایی، از منابع زیر به‌ترتیب اولویت استفاده کنید:

۱. پیام‌رسان

گروه تلگرام کلاس به‌عنوان بستر اصلی ارتباطات، اطلاع‌رسانی و بحث‌های علمی استفاده می‌شود. این فضا برای طرح پرسش‌هایی که پاسخ آنها برای سایر دانشجویان نیز مفید است، بسیار مناسب می‌باشد.

۲. گفت‌وگو با مدرس

برای مسائل شخصی، فوری، یا پیچیده، از راه‌های زیر استفاده کنید:

- پیش از شروع کلاس – فرصت کوتاه برای طرح سؤال
- در حین کلاس – با بلند کردن دست یا مطرح کردن سؤال در زمان مناسب
- ایمیل – ارسال سؤال به آدرس ایمیل

سیاست همکاری

بحث و گفت‌وگو درباره محتوای درس با هر کسی آزاد است و به شدت تشویق می‌شود. با این حال، رعایت اخلاق آکادمیک در تمامی تکالیف، پروژه‌ها، و آزمون‌ها الزامی است.

مجاز:

- بحث در مورد مفاهیم، الگوریتم‌ها، و ایده‌های کلی با همکلاسی‌ها
- استفاده از منابع آموزشی معتبر (کتاب‌ها، مقالات، مستندات رسمی)
- مطالعه کدهای نمونه برای درک بهتر مفاهیم
- استفاده از هوش مصنوعی به‌عنوان ابزار کمک‌آموزشی

غیرمجاز:

- کپی‌برداری کامل یا جزئی از راه‌حل سایر دانشجویان
- همکاری در نوشتن کد یا حل مسائل اختصاصی تکالیف
- استفاده از راه‌حل‌های آماده از اینترنت بدون ذکر منبع
- ارسال پاسخ‌های یکسان یا بسیار مشابه از چند دانشجو
- استفاده از هوش مصنوعی برای تولید پاسخ‌های کامل تکالیف یا پروژه

برنامه تدریس

پارت ۱: تکامل و مبانی هوش مصنوعی (۲ جلسه)

جلسه ۱: سیر تکامل هوش مصنوعی و مفاهیم بنیادین

مدرس: دکتر سعیدرضا خردپیشه

- معرفی کلی دوره و پیش نیازها.
- مرور تاریخی: از هوش مصنوعی نمادین (Symbolic AI) و سیستم‌های خبره گرفته تا یادگیری ماشین و یادگیری عمیق.
- ظهور مدل‌های بنیادین (Foundation Models) و تفاوت آن با مدل‌های سنتی.
- تفاوت‌های کلیدی: هوش مصنوعی مولد (Generative AI) در مقابل هوش مصنوعی سنتی.
- کاربردهای عملیاتی هوش مصنوعی مولد: تولید متن، تصویر، کد، ویدئو، صدا و سیستم‌های چندحالتی (Multimodal).
- مقدمه‌ای بر مدل‌های زبانی

جلسه ۲: مرور کامل شبکه‌های عصبی (Pre-requisite)

مدرس: دکتر سعیدرضا خردپیشه

- معماری: پرسپترون ساده تا پرسپترون چندلایه (MLP).
- توابع فعال‌سازی (Activation Functions):
 - Sigmoid، Tanh، ReLU، Leaky ReLU، GELU
- توابع هزینه (Loss Functions):
 - MAE، MSE
 - Binary Cross-Entropy، Cross-Entropy
- الگوریتم به‌روزرسانی وزن‌ها:
 - گرادینت نزولی (Gradient Descent) و انواع آن (SGD، Adam، RMSprop).
 - مفهوم Backpropagation (پس‌انتشار) و زنجیره‌ای مشتق‌گیری.
- تنظیم‌های فوق‌پارامتر (Hyperparameters): Epoch، Batch Size، Learning Rate.

پارت ۲: زیرساخت و مبانی مدل‌های زبانی (۶ جلسه)

جلسه ۳: Tokenization و Embedding

مدرس: میلاد وزان

- چرا ماشین‌ها به عدد نیاز دارند؟
 - تبدیل متن به عدد
 - اهمیت نمایش عددی برای پردازش
- روش‌های کلاسیک Vectorization
 - Bag of Words (BoW)
 - TF-IDF
 - One-hot encoding
 - n-grams
 - مزایا و معایب هر روش
- مفهوم Embedding
 - نگاشت کلمات به فضای برداری
 - کاهش ابعاد و حفظ معنا
- Word2Vec و GloVe
 - Skip-gram و CBOW

- تفاوت‌ها و کاربردها
- روش‌های مدرن توکن‌سازی
 - چرا کاراکتر یا کلمه نه؟
 - BPE (Byte-Pair Encoding)
 - WordPiece
 - SentencePiece
 - Structured Prompts و Special Tokens (بخش ۱,۲,۶ کتاب)
 - Tokenization Best Practices (بخش ۱,۲,۴ کتاب)
 - پیاده‌سازی با Hugging Face (بخش ۱,۲,۵ کتاب)
- مفهوم فاصله در فضای برداری
 - شباهت کسینوسی (Cosine Similarity)
 - فاصله اقلیدسی (Euclidean Distance)

جلسه ۴: معماری Transformer (بخش اول - Attention)

مدرس: میلاد وزان

- مشکل مدل‌های توالی‌محور قدیمی (LSTM، RNN).
- مکانیزم خودتوجهی (Self-Attention) و توجه چندسر (Multi-Head Attention).
- ریاضیات پشت Q ، K ، V (Query, Key, Value)
- Attention Pathologies (بخش ۱,۳,۱۱ کتاب)
 - Attention Sink
 - Attention Dilution
 - Other Attention Phenomena

جلسه ۵: معماری Transformer (بخش دوم - ساختار کامل)

مدرس: میلاد وزان

- موقعیت‌گذاری (Positional Encoding)
 - چرا موقعیت مهم است؟
 - Sinusoidal Encoding
 - Learned Positional Encoding
 - Relative Positional Encoding
- Original Encoder-Decoder Transformer
- Decoder-Only vs Encoder-Decoder
 - تفاوت‌ها و کاربردها
 - BERT (Encoder-based)
 - GPT (Decoder-based)
 - BART (Encoder-Decoder) و T5
- Visualizing Attention for Explainability - (بخش ۱,۳,۱۲ کتاب)

جلسه ۶: Prediction Heads و Embedding‌های مدرن

مدرس: دکتر سعیدرضا خردپیشه

- Prediction Heads: What Transformers Output - (بخش ۱,۴ کتاب)
 - Language Modeling Head (Pretraining) - بخش ۱,۴,۱
 - Conditional Generation Head (SFT / Instruction Following) - بخش ۱,۴,۲
 - Value Head (Regression for RL) - بخش ۱,۴,۳
 - Head Selection Summary - بخش ۱,۴,۴
 - HuggingFace Implementation - بخش ۱,۴,۵

- محدودیت‌های Embedding های ثابت
- Embedding های متنی (Contextual Embeddings)
 - ELMo
 - BERT به عنوان Embedding
 - استخراج Embedding از BERT

جلسه ۷: پایگاه‌های داده برداری + ChromaDB

مدرس: میلاد وزان

- چرا RDBMS برای داده‌های برداری کارایی ندارد؟
 - محدودیت‌های SQL در جستجوی شباهت
 - پیچیدگی محاسباتی
- مفهوم فضای معنایی (Semantic Space)
 - نگاشت داده‌ها به فضای برداری
- الگوریتم‌های جستجوی تقریبی نزدیک‌ترین همسایه (ANN)
 - LSH (Locality-Sensitive Hashing)
 - IVF (Inverted File Index)
 - HNSW (Hierarchical Navigable Small World)
 - مقایسه الگوریتم‌ها
- بخش عملی: ChromaDB
 - نصب و راه‌اندازی
 - ایجاد کلکسیون (Collection)
 - ذخیره‌سازی Embedding ها
 - انجام کوئری شباهت
- مقایسه پایگاه‌های داده برداری

جلسه ۸: چالش‌ها و محدودیت‌های LLM

مدرس: دکتر سعیدرضا خردپیشه

- توهم (Hallucination)
 - انواع Hallucination
 - Detection Methods
 - ریشه‌های توهم
- محدودیت پنجره زمینه (Context Window)
 - محدودیت توکن‌ها
 - راه‌حل‌ها: Sliding Window، Positional Interpolation
- تاریخ انقضای دانش (Knowledge Cutoff)
- سوگیری‌های داده (Bias)
- مسائل امنیتی - (بخش ۱۷، کتاب)
- عدم اتصال به واقعیت (Lack of Grounding)
- شکست در استدلال‌های چندمرحله‌ای (Multi-Step Reasoning Failure)

پارت ۳: استدلال

جلسه ۹: مهندسی پرامپت پیشرفته

مدرس: میلاد وزان

- بخش اول - مفاهیم پایه

- اهمیت پرامپت‌نویسی
- In-Context Learning (ICL) - بخش ۱,۱۳,۱
- Zero-shot Prompting - بخش ۱,۱۳,۲
- Few-shot Prompting - بخش ۱,۱۳,۳
- Instruction-Following Prompts - بخش ۱,۱۳,۴
- Structured Output Prompts (JSON/XML) - بخش ۱,۱۳,۵
- Best Practices
- **بخش دوم - Chain of Thought (CoT)**
 - مفهوم و اهمیت
 - وادار کردن مدل به فکر کردن گام به گام
 - Zero-shot CoT
 - Few-shot CoT
 - مثال‌های عددی و منطقی
- **بخش سوم - درخت و گراف افکار**
 - محدودیت‌های CoT
 - Tree of Thoughts (ToT)
 - Graph of Thoughts (GoT)
- **تکنیک‌های جدید Prompting**
 - Self-Ask
 - Plan-and-Solve

پارت ۴: دانش خارجی و RAG (۵ جلسه)

جلسه ۱۰: مبانی (RAG (Retrieval-Augmented Generation)

مدرس: دکتر سعیدرضا خردپیشه

- **چرا RAG؟**
 - ارتباط با جلسه ۸ و مشکل توهم
 - Parametric vs. Non-Parametric Knowledge - بخش ۱۶,۱,۱
 - When to Use RAG vs. Fine-Tuning vs. Long Context - بخش ۱۶,۱,۲
- **معماری کلی RAG - (بخش ۱۶,۲ کتاب)**
 - Full Pipeline Diagram - بخش ۱۶,۲,۱
 - Indexing Pipeline - بخش ۱۶,۲,۲
 - Retrieval - بخش ۱۶,۲,۳
 - Generation - بخش ۱۶,۲,۴
- **معرفی انواع RAG**
- **مفهوم تکه‌تکه‌سازی (Chunking) - (بخش ۱۶,۴ کتاب)**
 - Fixed-Size Chunking with Overlap - بخش ۱۶,۴,۱
 - Semantic Chunking - بخش ۱۶,۴,۲
 - Document-Structure-Aware Chunking - بخش ۱۶,۴,۳
 - Parent-Child Chunking - بخش ۱۶,۴,۴
 - Empirical Guidelines - بخش ۱۶,۴,۵

جلسه ۱۱: روش‌های پیشرفته بازیابی

مدرس: -

- **مشکل: اسناد بازیابی شده گاهی نامرتبط یا کم‌کیفیت هستند.**

- **Retrieval Methods** - (بخش ۱۶,۳ کتاب)
 - Sparse Retrieval: BM25 و TF-IDF - بخش ۱۶,۳,۱
 - Dense Retrieval: DPR - بخش ۱۶,۳,۲
 - Hybrid Retrieval با Reciprocal Rank Fusion - بخش ۱۶,۳,۳
 - Learned Sparse Retrieval: SPLADE و SPLADEv2 - بخش ۱۶,۳,۴
 - ColBERT: Late Interaction - بخش ۱۶,۳,۵
 - Retrieval Method Comparison - بخش ۱۶,۳,۶

• **CAG (Cache-Augmented Generation)**

• **KAG (Knowledge-Augmented Generation)**

جلسه ۱۲: بهینه‌سازی مرحله بازیابی (Retrieval Optimization)

مدرس: -

- **Query Transformation** - (بخش ۱۶,۵,۱ کتاب)
 - بازنویسی سوال
 - گسترش سوال
 - Multi-Query Retrieval
- **Re-Ranking** - (بخش ۱۶,۵,۲ کتاب)
 - مرتب‌سازی مجدد با Cross-Encoders
 - پیاده‌سازی و تأثیر بر دقت
- **Contextual Compression** - (بخش ۱۶,۵,۳ کتاب)
 - فشرده‌سازی متن برای کاهش توکن‌ها
- **Self-RAG** - (بخش ۱۶,۵,۴ کتاب)
 - بازتاب و خوداصلاحی در RAG
- **CRAG: Corrective RAG** - (بخش ۱۶,۵,۵ کتاب)
 - اصلاح بازیابی نادرست
- **Adaptive RAG** - (بخش ۱۶,۵,۶ کتاب)
 - تطبیق استراتژی بازیابی با سوال
- **Graph RAG** - (بخش ۱۶,۵,۷ کتاب)
 - استفاده از گراف دانش برای بازیابی
- **RAG-Fusion** - (بخش ۱۶,۵,۸ کتاب)
 - Multi-Query Retrieval

جلسه ۱۳: ارزیابی سیستم‌های RAG و مدل‌های زبانی بزرگ

مدرس: -

- **Evaluation Scheme Design** - (بخش ۱۴,۱ کتاب)
 - Taxonomy of Evaluation Types - بخش ۱۴,۱,۱
 - When to Use What - بخش ۱۴,۱,۲
- **Data Collection for Evaluation** - (بخش ۱۴,۲ کتاب)
 - Human Annotation Pipelines - بخش ۱۴,۲,۱
 - Inter-Annotator Agreement - بخش ۱۴,۲,۲
 - Annotation Guideline Design - بخش ۱۴,۲,۳
 - Crowdsourcing vs. Expert Annotation - بخش ۱۴,۲,۴

- **Synthetic Data Generation** - (بخش ۱۴,۳ کتاب)
 - LLM-as-Judge for Calibration - بخش ۱۴,۳,۱
 - Self-Instruct - بخش ۱۴,۳,۲
 - Evol-Instruct - بخش ۱۴,۳,۳
 - Constitutional AI Data Generation - بخش ۱۴,۳,۴
 - Distillation for Evaluation Data - بخش ۱۴,۳,۵
 - Arena-Style Pairwise Generation - بخش ۱۴,۳,۶
 - **Metrics for Generation Tasks** - (بخش ۱۴,۵ کتاب)
 - ROUGE، BLEU - بخش ۱۴,۵,۱ و ۱۴,۵,۲
 - BERTScore - بخش ۱۴,۵,۳
 - METEOR - بخش ۱۴,۵,۴
 - Perplexity - بخش ۱۴,۵,۵
 - Pass@k for Code - بخش ۱۴,۵,۶
 - F1 و Exact Match - بخش ۱۴,۵,۷
 - **ارزیابی RAG** - (بخش ۱۶,۸,۱ و ۱۶,۸,۲ کتاب)
 - **جلسه ۱۴: کارگاه عملی RAG (پروژه کامل)**
- مدرس: -
- **پیاده‌سازی یک سیستم RAG کامل**
 - انتخاب دامنه (پزشکی، حقوقی، فنی)
 - جمع‌آوری داده‌ها
 - پیش‌پردازش و Chunking
 - **بهینه‌سازی پارامترها**
 - Chunk Size
 - Overlap
 - Top-K
 - **Embedding Model Selection** - (بخش ۱۶,۹,۱ کتاب)
 - **اضافه کردن Chat History**
 - مکالمات چندمرحله‌ای
 - نگهداری تاریخچه
 - **استقرار سیستم**
 - API با FastAPI
 - رابط کاربری ساده
 - **Production Considerations** - (بخش ۱۶,۹ کتاب)
 - Latency Optimization - بخش ۱۶,۹,۳
 - Incremental Indexing and Versioning - بخش ۱۶,۹,۴

پارت ۵: Fine-tuning و بهینه‌سازی (۲ جلسه)

جلسه ۱۵: مبانی Fine-tuning و LoRA

مدرس: -

- **بخش اول - مبانی** - (بخش ۱,۸ کتاب)
 - SFT Objective - بخش ۱,۸,۱

- بخش ۱,۸,۲ - Data Quality: The LIMA Principle ○
- بخش ۱,۸,۳ - Training Configuration ○
- بخش ۱,۸,۴ - Efficient Training Solutions ○
- بخش ۱,۸,۵ - Best Practices ○
- بخش دوم - LoRA (Low-Rank Adaptation) - (بخش ۱,۹,۱ کتاب) •
- بخش سوم - LoRA Variants - (بخش ۱,۹,۳ کتاب) •
- بخش چهارم - Other PEFT Approaches - (بخش ۱,۹,۴ کتاب) •

جلسه ۱۶: تقطیر دانش (Knowledge Distillation) و فشردن مدل

مدرس: -

- Knowledge Distillation - (بخش ۱,۱۴,۳ کتاب)
 - معماری معلم-شاگرد (Teacher-Student)
 - انواع Distillation
 - پیاده‌سازی عملی
- مقایسه جامع روش‌های فشردن مدل - (بخش ۱,۱۴ کتاب)
 - Quantization - بخش ۱,۱۴,۱
 - Pruning - بخش ۱,۱۴,۲
- Structured vs. Unstructured
 - مزایا و معایب هر کدام
 - چه موقع از هر کدام استفاده کنیم؟
- Model Compression در عمل

پارت ۶: Agentic AI (۶ جلسه)

جلسه ۱۷: تعاریف و تمایزات کلیدی

مدرس: -

- Introduction to Agentic AI
 - تفاوت‌های دقیق:
 - Generative AI
 - AI Agent
 - Agentic AI
- معماری کلی یک Agent
 - Planning (برنامه‌ریزی)
 - Memory (حافظه)
 - Tool Use (استفاده از ابزار)
- Agent Harness - (فصل ۱۸ کتاب)
 - What Is an Agent Harness - بخش ۱۸,۱
 - Context Window Management - بخش ۱۸,۲
 - The Context Budget Problem - بخش ۱۸,۲,۱
 - Context Allocation Strategies - بخش ۱۸,۲,۲
 - Context Compression - بخش ۱۸,۲,۳
 - Sliding Window Approaches - بخش ۱۸,۲,۴
 - Recursive Context Decomposition - بخش ۱۸,۲,۵
 - Token Counting and Budget Monitoring - بخش ۱۸,۲,۶

- **Prompt Architecture** - (بخش ۱۸,۳ کتاب)
 - System Prompt Design - بخش ۱۸,۳,۱
 - Dynamic Prompt Assembly - بخش ۱۸,۳,۲
 - Few-Shot Management - بخش ۱۸,۳,۳
 - Tool Descriptions - بخش ۱۸,۳,۴
- معرفی استاندارد MCP - (فصل ۲۱ کتاب)
 - Motivation: The Tool Integration Problem - بخش ۲۱,۱
 - Architecture Overview - بخش ۲۱,۲
 - Core Primitives - بخش ۲۱,۳

جلسه ۱۸: معماری Agent و Tool Calling

مدرس: -

- بخش اول - **Function Calling و Tool Calling**
- مفهوم **Tool Calling** یا **Function Calling**
- بخش دوم - **Agent در Tool Integration**
- نحوه اتصال **Tool Calling** به حلقه استدلال **Agent** - (بخش ۱۸,۴ کتاب)
 - Tool Definition Schemas - بخش ۱۸,۴,۱
 - Tool Selection and Routing - بخش ۱۸,۴,۲
 - Tool Output Processing - بخش ۱۸,۴,۳
 - Sandboxing and Safety - بخش ۱۸,۴,۴
- استفاده از MCP برای **Tool Calling** - (بخش ۲۱,۷ کتاب)
 - Building an MCP Server - بخش ۲۱,۷,۱
 - Building an MCP Client - بخش ۲۱,۷,۲
 - Connecting to Multiple Servers - بخش ۲۱,۷,۳
- مقایسه پیاده‌سازی در فریم‌ورک‌ها - (بخش ۱۸,۹ و ۲۵ کتاب)

جلسه ۱۹: الگوهای طراحی Agent

مدرس: -

- **Workflow Patterns** - (بخش ۱۹,۱ کتاب)
 - Prompt Chaining - بخش ۱۹,۱,۱
 - Routing - بخش ۱۹,۱,۲
 - Parallelization - بخش ۱۹,۱,۳
 - Orchestrator-Workers - بخش ۱۹,۱,۴
 - Evaluator-Optimizer - بخش ۱۹,۱,۵
- **Autonomous Agent Patterns** - (بخش ۱۹,۲ کتاب)
 - ReAct (Reason + Act) - بخش ۱۹,۲,۱
 - Planning Agents - بخش ۱۹,۲,۲
 - Reflection and Self-Critique - بخش ۱۹,۲,۳
 - Tool-Use Patterns - بخش ۱۹,۲,۴
- **Orchestration Patterns** - (بخش ۱۸,۵ کتاب)
 - ReAct Loop - بخش ۱۸,۵,۱
 - Plan-and-Execute - بخش ۱۸,۵,۲
 - Multi-Agent Orchestration - بخش ۱۸,۵,۳

- بخش ۱۸,۵,۴ - Human-in-the-Loop
- بخش ۱۸,۵,۵ - Workflow Graphs
- **State Management** - (بخش ۱۸,۶ کتاب)
- بخش ۱۸,۶,۱ - Conversation State
- بخش ۱۸,۶,۲ - Task State
- بخش ۱۸,۶,۳ - Agent State
- بخش ۱۸,۶,۴ - Persistent State
- **Error Handling and Recovery** - (بخش ۱۸,۷ کتاب)
- بخش ۱۸,۷,۱ - Retry Strategies
- بخش ۱۸,۷,۲ - Loop Detection
- بخش ۱۸,۷,۳ - Graceful Failure
- بخش ۱۸,۷,۴ - Observability

جلسه ۲۰: سیستم‌های چندعامله (Multi-Agent Systems) - بخش اول

مدرس: -

- **Why Multiple Agents** - (بخش ۲۴,۱ کتاب)
- **Multi-Agent Architectures** - (بخش ۲۴,۲ کتاب)
 - بخش ۲۴,۲,۱ - Centralized (Supervisor/Manager)
 - بخش ۲۴,۲,۲ - Decentralized (Peer-to-Peer)
 - بخش ۲۴,۲,۳ - Hierarchical
 - بخش ۲۴,۲,۴ - Swarm Architecture
- **Coordination Mechanisms** - (بخش ۲۴,۳ کتاب)
 - بخش ۲۴,۳,۱ - Shared State (Global Blackboard)
 - بخش ۲۴,۳,۲ - Message Passing
 - بخش ۲۴,۳,۳ - Planning and Decomposition
 - بخش ۲۴,۳,۴ - Voting and Consensus
 - بخش ۲۴,۳,۵ - Market-Based Coordination
 - بخش ۲۴,۳,۶ - Stigmergy
- **Communication Protocols** - (بخش ۲۴,۴ کتاب)
 - بخش ۲۴,۴,۱ - Structured Message Formats
 - بخش ۲۴,۴,۲ - Performative Types
 - بخش ۲۴,۴,۳ - Context Sharing Strategies
- **Agent-to-Agent Communication (A2A)** - (فصل ۲۳ کتاب)
 - بخش ۲۳,۱ - Motivation
 - بخش ۲۳,۲ - The Google A2A Protocol
 - بخش ۲۳,۳ - Communication Patterns
 - بخش ۲۳,۴ - Agent Discovery and Routing

جلسه ۲۱: پیاده‌سازی عملی Multi-Agent

مدرس: -

- پیاده‌سازی سناریوی چندعامله
 - تعریف عامل‌ها:

- Researcher (جستجو)
- Writer (نگارش)
- Editor (بازبینی)
- تعریف وظایف (Tasks)
- اجرای فرآیند و مشاهده همکاری
- پیاده‌سازی سناریوی مناظره (Debate)
 - دو عامل با نقش‌های مخالف (Con و Pro)
 - عامل داور (Judge) برای انتخاب پاسخ نهایی
- **Role Design and Specialization** - (بخش ۲۴,۵ کتاب)
 - Defining Agent Roles - بخش ۲۴,۵,۱
 - Capability-Based vs. Role-Based Assignment - بخش ۲۴,۵,۲
 - Dynamic Role Reassignment - بخش ۲۴,۵,۳
 - Persona Design - بخش ۲۴,۵,۴
- **Multi-Agent Patterns for LLMs** - (بخش ۲۴,۶ کتاب)
 - Debate Pattern - بخش ۲۴,۶,۱
 - Reflection Pattern - بخش ۲۴,۶,۲
 - Division of Labor Pattern - بخش ۲۴,۶,۳
 - Pipeline Pattern - بخش ۲۴,۶,۴
 - Ensemble Pattern - بخش ۲۴,۶,۵
 - Teacher-Student Pattern - بخش ۲۴,۶,۶
 - Red Team Pattern - بخش ۲۴,۶,۷

جلسه ۲۲: حافظه در سیستم‌های Agentic

مدرس: -

- **Motivation: Why Agents Need Memory** - (بخش ۱۷,۱ کتاب)
- **Taxonomy of Memory Types** - (بخش ۱۷,۲ کتاب)
 - Working Memory (Short-Term) - بخش ۱۷,۲,۱
 - Episodic Memory (Experience-Based) - بخش ۱۷,۲,۲
 - Semantic Memory (World Knowledge) - بخش ۱۷,۲,۳
 - Procedural Memory (Skills) - بخش ۱۷,۲,۴
- **Memory Architectures** - (بخش ۱۷,۳ کتاب)
 - RAG-Based Memory - بخش ۱۷,۳,۱
 - Summarization-Based Memory - بخش ۱۷,۳,۲
 - Graph-Based Memory - بخش ۱۷,۳,۳
 - Key-Value Memory Networks - بخش ۱۷,۳,۴
 - MemGPT and Virtual Context Management - بخش ۱۷,۳,۵
- **Memory Operations** - (بخش ۱۷,۴ کتاب)
 - Write: Committing to Memory - بخش ۱۷,۴,۱
 - Read / Retrieve - بخش ۱۷,۴,۲
 - Update: Conflict Resolution - بخش ۱۷,۴,۳
 - Reflect: Meta-Cognitive Operations - بخش ۱۷,۴,۴
- **Memory for Multi-Turn Conversations** - (بخش ۱۷,۵ کتاب)
 - User Modeling - بخش ۱۷,۵,۱

- Session Continuity - بخش ۱۷,۵,۲
- Personalization - بخش ۱۷,۵,۳
- **Memory for Multi-Agent Systems** - (بخش ۱۷,۶ کتاب)
 - Shared Memory Pools - بخش ۱۷,۶,۱
 - Blackboard Architecture - بخش ۱۷,۶,۲
 - Consensus and Conflict - بخش ۱۷,۶,۳
- **Recent Advances in Agentic Memory** - (بخش ۱۷,۱۱ کتاب)
 - CoALA - بخش ۱۷,۱۱,۱
 - Mem0 - بخش ۱۷,۱۱,۲
 - Sleep-Time Compute - بخش ۱۷,۱۱,۳
 - A-MEM - بخش ۱۷,۱۱,۴

پارت ۷: مباحث تکمیلی و پیشرفته (۳ جلسه)

جلسه ۲۳: معماری‌های پیشرفته و مدل‌های جدید

مدرس: -

- معماری‌های فراتر از Transformer
 - Mamba و State Space Models (SSM)
 - RWKV
 - Hybrid Models (Mamba + Attention)
- **Mixture of Experts (MoE)** - (بخش ۱,۱۰ کتاب)
 - Architecture - بخش ۱,۱۰,۱
 - Load Balancing - بخش ۱,۱۰,۲
 - Noisy Top-K Gating - بخش ۱,۱۰,۳
 - Notable MoE Models - بخش ۱,۱۰,۴
- **Diversity in LLM Training** - (بخش ۱,۱۱ کتاب)
 - Sampling Diversity - بخش ۱,۱۱,۱
 - Training Data Diversity - بخش ۱,۱۱,۲
 - Diversity-Promoting Methods - بخش ۱,۱۱,۳
- **Text Generation: Decoding Methods** - (بخش ۱,۱۲ کتاب)
 - Greedy Decoding - بخش ۱,۱۲,۱
 - Beam Search - بخش ۱,۱۲,۲
 - Diverse Beam Search - بخش ۱,۱۲,۳
 - Top-k Sampling - بخش ۱,۱۲,۴
 - Top-p (Nucleus) Sampling - بخش ۱,۱۲,۵
 - Min-p Sampling - بخش ۱,۱۲,۶
 - Temperature Scaling - بخش ۱,۱۲,۷
 - Contrastive Decoding - بخش ۱,۱۲,۸
 - Repetition Penalties - بخش ۱,۱۲,۹
 - Constrained Decoding - بخش ۱,۱۲,۱۱
- مدل‌های **Reasoning** پیشرفته - (فصل ۱۳ کتاب)
 - DeepSeek-R1 - بخش ۱۳,۳
- Two-Stage Training Pipeline - بخش ۱۳,۳,۱

- بخش ۱۳,۳,۲ - Reward Design
- بخش ۱۳,۳,۳ - GRPO Formulation
- بخش ۱۳,۳,۴ - Distillation: R1-Distill
- بخش ۱۳,۴ - OpenAI o1/o3
- بخش ۱۳,۴,۱ - CoT RL with Hidden Reasoning Tokens
- بخش ۱۳,۴,۲ - Process Reward Models vs. Outcome Reward Models
- بخش ۱۳,۴,۳ - Inference-Time Compute Scaling
- بخش ۱۳,۴,۴ - Training Compute vs. Test-Time Compute
- بخش ۱۳,۵ - QwQ and Qwen Reasoning Models
- بخش ۱۳,۵,۱ - Multi-Stage RL Pipeline
- بخش ۱۳,۵,۲ - Rejection Sampling + RL
- بخش ۱۳,۵,۳ - Tool-Integrated Reasoning
- **Scaling Laws for Reasoning** (بخش ۱۳,۷ کتاب)
- بخش ۱۳,۷,۱ - Training Compute vs. Test-Time Compute Tradeoff
- بخش ۱۳,۷,۳ - Optimal Token Budget Allocation

جلسه ۲۴: ارزیابی و تست سیستم‌های Agentic

مدرس: -

- **Metrics for Agentic Tasks** (بخش ۱۴,۶ کتاب)
 - بخش ۱۴,۶,۱ - Task Success Rate
 - بخش ۱۴,۶,۲ - Trajectory Efficiency
 - بخش ۱۴,۶,۳ - Tool-Use Accuracy
 - بخش ۱۴,۶,۴ - Multi-Step Reasoning Accuracy
 - بخش ۱۴,۶,۵ - SWE-bench Methodology
 - بخش ۱۴,۶,۶ - WebArena Methodology
- **LLM-as-Judge** (بخش ۱۴,۷ کتاب)
 - بخش ۱۴,۷,۱ - Setup and Prompt Templates
 - بخش ۱۴,۷,۲ - Position Bias Mitigation
 - بخش ۱۴,۷,۳ - Multi-Judge Panels
 - بخش ۱۴,۷,۴ - Agreement Metrics
 - بخش ۱۴,۷,۵ - G-Eval Framework
- **Evaluation Pitfalls** (بخش ۱۴,۸ کتاب)
 - بخش ۱۴,۸,۱ - Benchmark Contamination
 - بخش ۱۴,۸,۲ - Overfitting to Benchmarks
 - بخش ۱۴,۸,۳ - Goodhart's Law in Evaluation
 - بخش ۱۴,۸,۴ - Additional Pitfalls
- **Agent Testing and Evaluation** (بخش ۲۵,۵ کتاب)
 - بخش ۲۵,۵,۱ - Unit Testing Individual Tools
 - بخش ۲۵,۵,۲ - Integration Testing Full Agent Loops
 - بخش ۲۵,۵,۳ - Regression Testing with Golden Trajectories
 - بخش ۲۵,۵,۴ - Behavioral Testing
 - بخش ۲۵,۵,۵ - Cost and Latency Testing

- **LLM Safety and Responsible AI** - (بخش ۱,۱۷ کتاب)
 - Threat Taxonomy - بخش ۱,۱۷,۱
 - Safety Training Pipeline - بخش ۱,۱۷,۲
 - Key Safety Mechanisms - بخش ۱,۱۷,۳
 - The Helpfulness-Safety Tradeoff - بخش ۱,۱۷,۴
 - Evaluation - بخش ۱,۱۷,۵
- **Security in Multi-Agent Systems** - (بخش ۲۳,۸ کتاب)
 - Agent Identity Verification - بخش ۲۳,۸,۱
 - Message Integrity and Encryption - بخش ۲۳,۸,۲
 - Authorization Scopes - بخش ۲۳,۸,۳
 - Audit Trails and Accountability - بخش ۲۳,۸,۴
- **MCP Security Model** - (بخش ۲۱,۶ کتاب)
 - Trust Hierarchy - بخش ۲۱,۶,۱
 - User Consent - بخش ۲۱,۶,۲
 - Input Validation - بخش ۲۱,۶,۳
 - Credential Management - بخش ۲۱,۶,۴
 - Sandboxing Strategies - بخش ۲۱,۶,۵
- **Production Deployment Patterns** - (بخش ۲۵,۷ کتاب)
 - Async Agent Execution - بخش ۲۵,۷,۱
 - Multi-Tenant Isolation - بخش ۲۵,۷,۲
 - Cost Optimization Strategies - بخش ۲۵,۷,۳
 - Auto-Scaling Strategies - بخش ۲۵,۷,۴
- **Observability and Debugging** - (بخش ۲۵,۶ کتاب)
 - Tracing Agent Execution - بخش ۲۵,۶,۱
 - Failure Categorization - بخش ۲۵,۶,۲
 - Replay and Debugging Workflows - بخش ۲۵,۶,۳
- **Scaling and Production Concerns** - (بخش ۱۸,۸ کتاب)
 - Latency Optimization - بخش ۱۸,۸,۱
 - Cost Management - بخش ۱۸,۸,۲
 - Rate Limiting and Queuing - بخش ۱۸,۸,۳
 - Evaluation in Production - بخش ۱۸,۸,۴

جلسه ۲۶: پروژه پایانی

- ارائه پروژه پایانی توسط دانشجویان:
 - نقد و بررسی پروژه‌ها توسط استاد و دیگر دانشجویان.

مراجع و منابع درس

برای این درس، یک کتاب درسی مشخص و واحد وجود ندارد. در عوض، محتوای آموزشی از ترکیبی از منابع معتبر و به‌روز شامل کتاب‌های تخصصی، مقالات علمی و مستندات فنی گردآوری می‌شود.

با این حال، یک منبع بسیار ارزشمند و جامع که می‌تواند به عنوان یک مرجع اصلی و راهنمای عملی برای بخش‌های زیادی از این درس مورد استفاده قرار گیرد، کتاب زیر است:

عنوان: The Hitchhiker's Guide to Agentic AI: From Foundations to Systems










نویسنده: Haggai Roitman


سال انتشار: ۲۰۲۶

دسترسی: [arXiv:2606.24937](https://arxiv.org/abs/2606.24937)

این کتاب که به تازگی منتشر شده، یک مرجع کامل و عملی برای ساخت سیستم‌های هوش مصنوعی عامل محور است.


کتاب‌های مرجع تکمیلی:





Formal Aspects of Language Modeling

Ryan Cotterell, Aarj Bore, Chen Meister,
Tianyi Liu, and Li Du
Thursday 18th April, 2024



مقالات علمي:

- a. [Attention Is All You Need](#)
- b. [BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding](#)
- c. [Mamba: Linear-Time Sequence Modeling with Selective State Spaces](#)
- d. [LoRA: Low-Rank Adaptation of Large Language Models](#)
- e. [QLoRA: Efficient Finetuning of Quantized LLMs](#)
- f. [Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism](#)
- g. [Efficient Memory Management for Large Language Model Serving with PagedAttention](#)
- h. [Chain-of-Thought Prompting Elicits Reasoning in Large Language Models](#)
- i. [Tree of Thoughts: Deliberate Problem Solving with Large Language Models](#)
- j. [ReAct: Synergizing Reasoning and Acting in Language Models](#)
- k. [Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks](#)
- l. [REALM: Retrieval-Augmented Language Model Pre-Training](#)
- m. [Generative to Agentic AI: Survey, Conceptualization, and Challenges](#)
- n. [Sparks of Artificial General Intelligence: Early experiments with GPT-4](#)
- o. [A Survey on Large Language Models with some Insights on their Capabilities and Limitations](#)
- p. [Agentic Large Language Models, a survey](#)
- q. [AI Agents vs. Agentic AI: A Conceptual taxonomy, applications and challenges](#)
- r. [Agentic Artificial Intelligence \(AI\): Architectures, Taxonomies, and Evaluation of Large Language Model Agents](#)
- s. [The Rise of Agentic AI: A Review of Definitions, Frameworks, Architectures, Applications, Evaluation Metrics, and Challenges](#)
- t. [Towards Reasoning Era: A Survey of Long Chain-of-Thought for Reasoning Large Language Models](#)
- u. [How to think step-by-step: A mechanistic understanding of chain-of-thought reasoning](#)
- v. [Agentic Reasoning for Large Language Models](#)
- w. [Large Language Model Reasoning Failures](#)
- x. [Memory in the Age of AI Agents](#)
- y. [Multi-Agent Collaboration Mechanisms: A Survey of LLMs](#)
- z. [Why Language Models Hallucinate](#)
- aa. [A Survey on Knowledge Distillation of Large Language Models](#)
- bb. [The Vector Grounding Problem](#)